Диагностика обучения MLP

Отчёт по лабораторной работе № 1

Цель работы. Исследовать влияние функций активации, инициализации весов, глубины многослойного перцептрона и режима оптимизации на обучение и качество бинарной классификации. Проведено 12 экспериментов: шесть конфигураций модели с двумя значениями начального состояния генератора случайных чисел (seed).

1. Подготовка данных

Сгенерированы 2400 объектов командой make_moons(n_samples=2400, noise=0.25, random_state=2026). Два последовательных стратифицированных train_test_split используют random_state=2026 и test_size=0.2, затем 0.25. Разбиение одинаково для всех экспериментов.

Выборка	Объекты	Класс 0	Класс 1
train	1440	720	720
validation	480	240	240
test	480	240	240

Параметры стандартизации StandardScaler рассчитаны только по обучающей выборке. Средние значения признаков после преобразования составили 2.066e-17 и 6.216e-16, стандартные отклонения - 1.000000 и 1.000000. Таким образом, признаки центрированы и имеют единичную дисперсию. Исключение validation и test из расчёта параметров стандартизации предотвращает утечку информации.

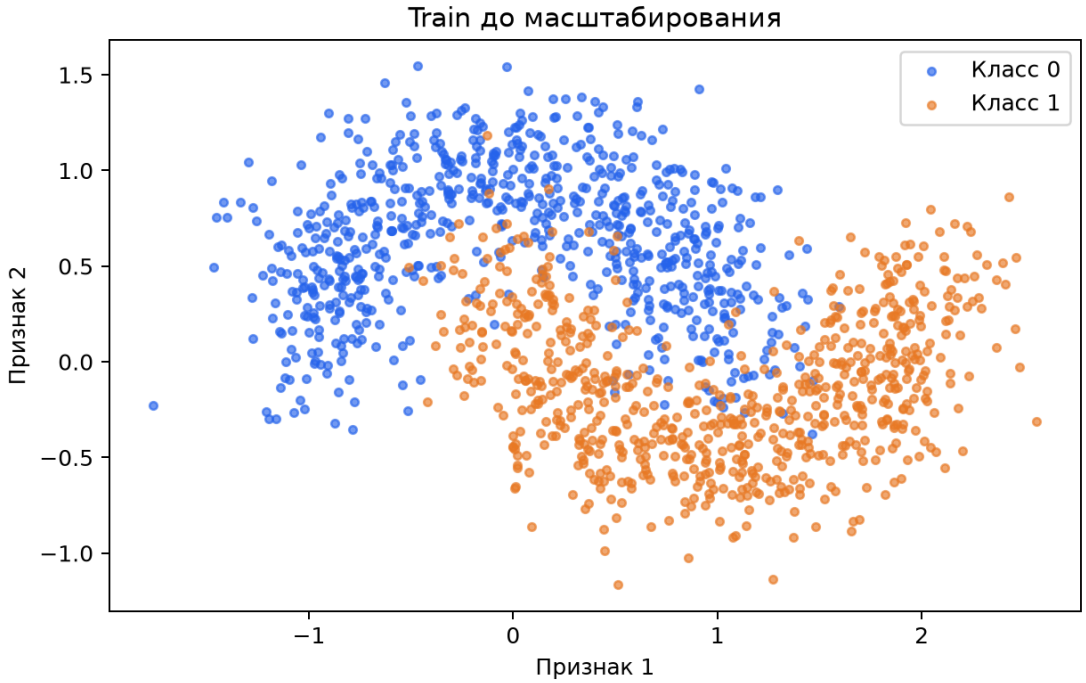


Рисунок 1. Исходные обучающие объекты до масштабирования, цветом обозначен класс.

2. Архитектура и протокол обучения

MLP получает два признака, содержит L полносвязных скрытых слоёв ширины 32 и линейный выход из двух логитов. Во всех скрытых слоях одного запуска используется одна активация. Softmax перед CrossEntropyLoss не применяется.

$$h_0 = x;\ z_l = W_l h_{l-1} + b_l;\ h_l = \varphi(z_l),\ l = 1,\ldots,L.$$
$$z_{out} = W_{L+1} h_L + b_{L+1} \in R^2.$$

Первый скрытый слой имеет W формы (32, 2), остальные - (32, 32), выходной - (2, 32). Размеры bias: 32 для скрытых слоёв и 2 для выхода.

Число параметров

$N(L) = (2\cdot32 + 32) + (L - 1)\cdot(32\cdot32 + 32) + (32\cdot2 + 2)$.
$N(1) = 162$; $N(6) = 5442$. Аналитический расчёт совпал с программным подсчётом числа обучаемых параметров.

Код	L	Активация	Скрытые веса	Оптимизатор	LR
A	6	Sigmoid	Xavier normal	Adam	0.003
B	6	Tanh	Xavier normal	Adam	0.003
C	6	ReLU	Xavier normal	Adam	0.003
D	6	ReLU	He normal	Adam	0.003
E	6	ReLU	He normal	SGD	0.05
F	1	ReLU	He normal	Adam	0.003

Xavier normal задан с gain=1.0. He/Kaiming normal - с mode=fan_in, nonlinearity=relu. Выходной Linear во всех вариантах инициализирован Xavier normal с gain=1.0, все bias равны нулю. Для SGD установлен momentum=0; остальные параметры оптимизаторов, кроме LR, оставлены по умолчанию.

Методика обучения

Использованы слои torch.nn, дифференцирование autograd и оптимизаторы SGD/Adam. Конструктор MLP, инициализация, цикл обучения, расчёт метрик и диагностика градиентов реализованы самостоятельно.

Каждый запуск: 100 эпох, batch size 128, перемешивание train в каждой эпохе. До создания модели вызывается torch.manual_seed(seed), для DataLoader создаётся новый torch.Generator().manual_seed(10000 + seed). Seed: 11 и 29. Устройство cpu, torch.set_num_threads(1), признаки float32, метки torch.long.

Шаг обучения: zero_grad → forward → CrossEntropyLoss(mean) → backward → optimizer.step. На эпохе 0 и после каждой эпохи loss и accuracy оцениваются на полных train и validation в eval/no_grad; перед обучением включается train. Accuracy вычисляется через argmax как доля от 0 до 1. Проверяется конечность loss. Scheduler, dropout, batch normalization, weight decay, early stopping и предварительное обучение отсутствуют.

Контроль корректности реализации

При L=1 и L=6 вход и выход имеют размерность (8, 2), функция потерь скалярна. Градиенты всех скрытых весов существуют, конечны и совпадают по размерностям с соответствующими матрицами весов.

3. Итоговые метрики всех запусков

Таблица 1. Метрики эпохи 100. Accuracy указана долей правильных ответов.

Код	Seed	Train loss	Train acc.	Val loss	Val acc.
A	11	0.150452	0.945833	0.190750	0.916667
A	29	0.140309	0.945833	0.177103	0.916667
B	11	0.146706	0.946528	0.203395	0.912500
B	29	0.143581	0.948611	0.189271	0.918750
C	11	0.120760	0.951389	0.180691	0.920833
C	29	0.129302	0.945833	0.224080	0.910417
D	11	0.108775	0.953472	0.212312	0.922917
D	29	0.114085	0.952083	0.206341	0.914583
E	11	0.254591	0.884722	0.346126	0.858333
E	29	0.303343	0.865278	0.355739	0.839583
F	11	0.136744	0.949306	0.167788	0.929167
F	29	0.138208	0.949306	0.167623	0.922917

Таблица 2. Средний validation loss эпохи 100 по двум seed.

Конфигурация	A	B	C	D	E	F
Mean val loss	0.183927	0.196333	0.202386	0.209326	0.350932	0.167705

Активации при Xavier normal

На эпохе 1 при seed 11 validation loss A/B/C равен 0.6935/0.3522/0.4296. При seed 11 на эпохе 20 validation loss A/B/C равен 0.3445/0.1745/0.2112. Sigmoid обучается заметно медленнее; впервые val loss < 0.2 достигается на эпохах 66/5/4. На эпохе 100 порядок меняется: C (0.1807) лучше A (0.1908) и B (0.2034).

При seed 29 раннее отставание A повторяется: loss эпохи 20 A/B/C = 0.3271/0.1741/0.1755; порог 0.2 достигнут на эпохах 56/4/4. Однако на эпохе 100 A (0.1771) лучше B (0.1893) и C (0.2241). Раннее замедление Sigmoid устойчиво в этих двух запусках, итоговое превосходство ReLU - нет. Вывод относится к Xavier normal с gain=1.0.

Инициализация ReLU

Дисперсия He равна 2/fan_in, Xavier - 2/(fan_in + fan_out): в квадратных слоях это 2/32 против 1/32, в первом - 1 против 2/34. Масштаб меняет активации и градиенты. На эпохе 20 переход C → D снижает validation loss с 0.2112 до 0.1704 при seed 11 и с 0.1755 до 0.1690 при seed 29. Но на эпохе 100 D хуже C при seed 11 и лучше при seed 29. Средний итоговый loss D (0.2093) выше C (0.2024); He не гарантирует лучшую validation-оценку.

4. Динамика обучения и сравнения режимов

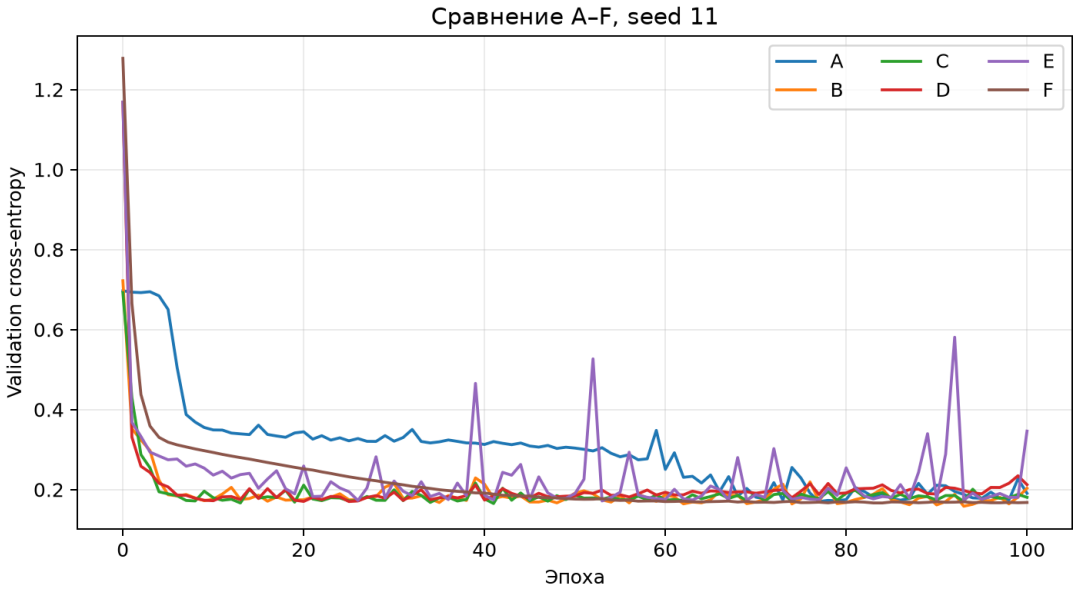


Рисунок 2. Validation loss A-F по эпохам, seed 11.

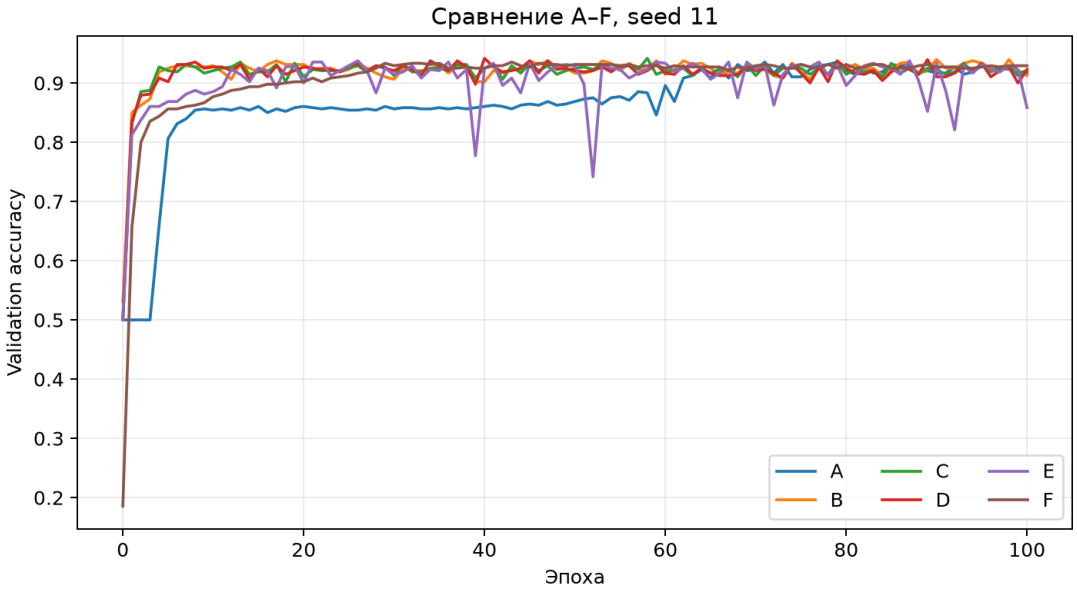


Рисунок 3. Validation accuracy A-F по эпохам, seed 11.

D/E. Порог val loss < 0.2 достигнут D на эпохах 6/5, E - на 19/21 (seed 11/29). На эпохе 100 D лучше E для обоих seed. В E между эпохами 99 и 100 train loss растёт 0.1277 → 0.2546 и 0.1337 → 0.3033; одновременно растёт validation loss. Это признак нестабильной оптимизации, а не только переобучения. Сравнение относится к Adam 0.003 и SGD 0.05: влияние оптимизатора отдельно от LR не установлено.

D/F. D быстрее достигает порога 0.2 (6/5 против 35/42 эпох), но F имеет меньший итоговый validation loss при обоих seed. D лучше подгоняет train: loss 0.1141 против 0.1382 у F для seed 29. В D 5442 параметра против 162 у F; влияние глубины нельзя отделить от изменения числа параметров.

5. Диагностика градиентов по слоям

Контрольный batch - первые 128 объектов train после разбиения и масштабирования в сохранённом порядке. На эпохах 0, 20 и 100 отдельно выполняются zero_grad, forward, backward, измерение нормы и повторный zero_grad; параметры не обновляются. Измеряется $g_l(t) = ||\partial CE(f_\theta(t)(X_{probe}), y_{probe})/\partial W_l||_F$.

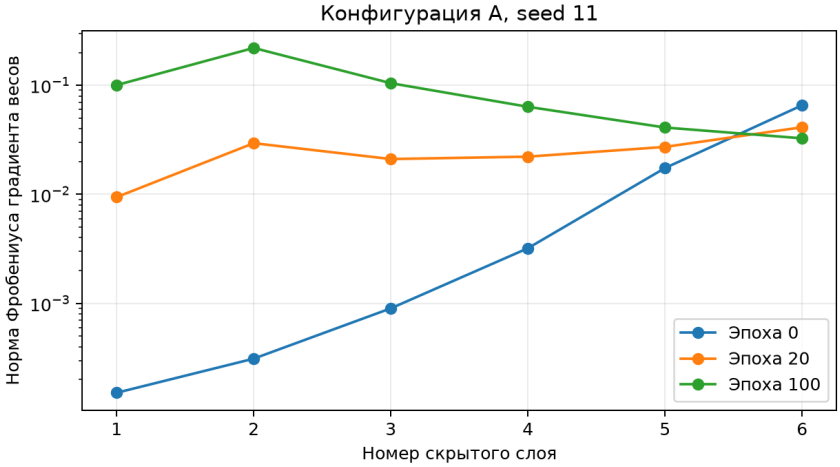


Рисунок 4. Нормы градиентов скрытых весов A, seed 11; логарифмическая ось Y.

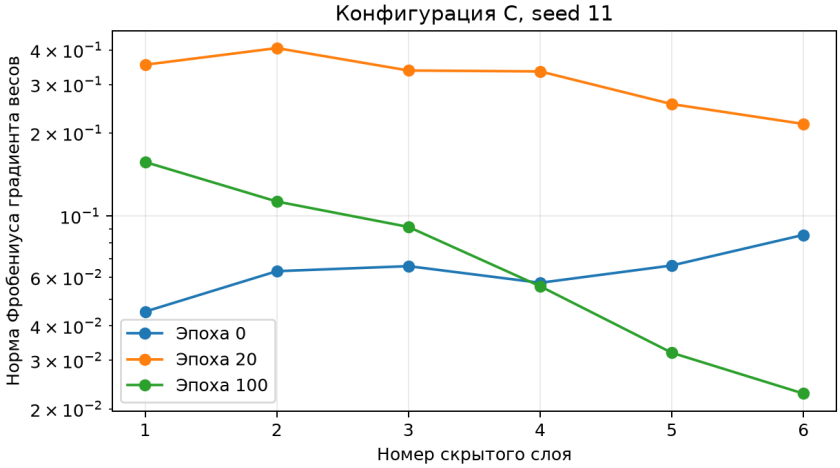


Рисунок 5. Нормы градиентов скрытых весов C, seed 11; логарифмическая ось Y.

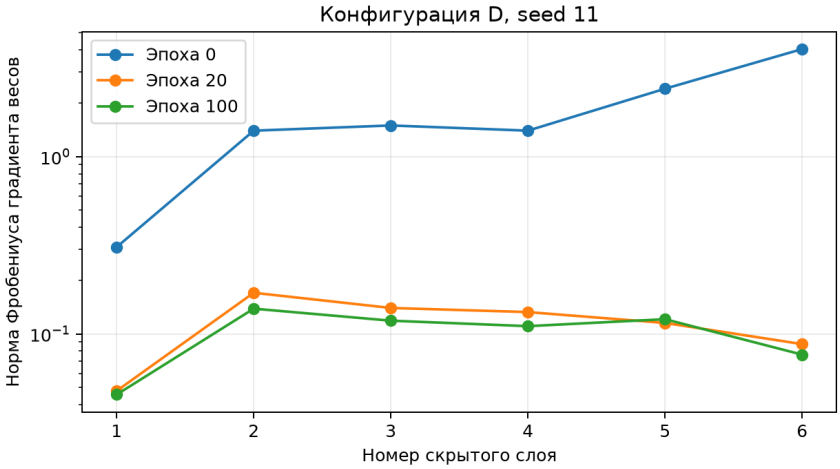


Рисунок 6. Нормы градиентов скрытых весов D, seed 11; логарифмическая ось Y.

6. Объяснение градиентной диагностики

Таблица 3. Нормы градиентов весов первого и последнего скрытых слоёв для двух значений seed.

Код	Seed	Эпоха	g_1	g_6
A	11	0	1.516e-04	6.565e-02
A	11	20	9.437e-03	4.127e-02
A	11	100	1.005e-01	3.265e-02
A	29	0	1.902e-04	1.223e-01
A	29	20	1.033e-02	3.373e-02
A	29	100	7.405e-02	1.929e-03
C	11	0	4.505e-02	8.548e-02
C	11	20	3.538e-01	2.158e-01
C	11	100	1.570e-01	2.273e-02
C	29	0	9.655e-02	9.255e-02
C	29	20	1.423e-01	2.937e-02
C	29	100	3.022e-01	3.137e-02
D	11	0	3.088e-01	4.039e+00
D	11	20	4.771e-02	8.762e-02
D	11	100	4.549e-02	7.643e-02
D	29	0	2.654e-01	9.643e-01
D	29	20	1.239e-01	1.214e-01
D	29	100	1.515e-01	1.022e-01

Sigmoid и правило цепочки. При seed 11 начальные g_1/g_6 в A равны 1.516e-04/6.565e-02: ранний слой имеет примерно в 433 раза меньшую норму. При seed 29 разница составляет 643 раза. В цепочке производных Sigmoid множители $\varphi'(z) \leq 1/4$ могут многократно ослаблять сигнал. В C начальные нормы первого и шестого слоёв одного порядка: 0.045/0.085 и 0.097/0.093. У активных ReLU производная равна 1; однако веса и неактивные нейроны также влияют на результат.

C/D. На эпохе 0 He повышает g_1 с 0.045 до 0.309 (seed 11) и с 0.097 до 0.265 (seed 29); масштаб g_6 также выше. На эпохе 100 в D g_1 ниже C, а g_6 выше C для обоих seed. Стартовые масштабы и дальнейшая динамика различаются; большее начальное значение нормы не означает меньший итоговый validation loss.

Все 108 норм конечны и положительны; нулевые нормы отсутствуют. Основные наблюдения повторяются на seed 29: ослабление раннего градиента A в начале и увеличение начальных норм D относительно C. Конкретные величины после обучения сильно различаются.

7. Выбор модели и оценка обобщения

Критерием выбора конфигурации служило среднее значение validation loss на эпохе 100 по двум значениям seed. Внутри выбранной конфигурации использован запуск с меньшим validation loss. При точном равенстве предусмотрен выбор более ранней буквы конфигурации и seed 11. Промежуточные эпохи при выборе не учитывались.

Минимум среднего validation loss: F, 0.167705. Для F loss seed 11 равен 0.167788, seed 29 - 0.167623; выбран seed 29. Загружено сохранённое состояние эпохи 100. Только после выбора выполнена оценка test; её результаты не использовались для изменения модели.

Выборка	Cross-entropy loss	Accuracy
Train	0.138208	0.949306
Validation	0.167623	0.922917
Test	0.131385	0.950000

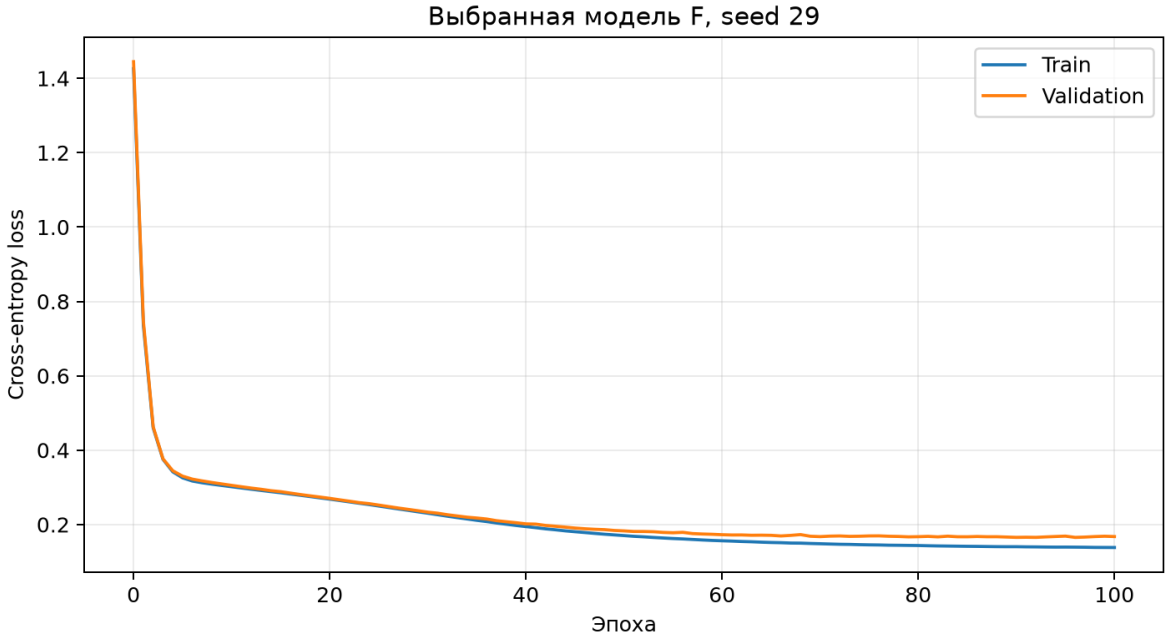


Рисунок 7. Train и validation loss выбранного запуска F, seed 29.

На train модель правильно классифицирует 94.93% объектов; loss снижается с 1.4259 до 0.1382. Обучение не осталось на плато случайного угадывания. Validation loss снижается с 1.4447 до 0.1676; разрыв с train на последней эпохе равен 0.0294.

Небольшой положительный разрыв train/validation у F указывает на различие подгонки и обобщения, но не на сильное ухудшение validation на протяжении всего обучения. Test accuracy около 0.95 согласуется с хорошим качеством на отдельной отложенной выборке. Test loss ниже validation loss может объясняться различием конкретных объектов и шума; это не доказывает систематически лучшее качество на test. Оценка относится к одному фиксированному разбиению.

В более глубокой D train loss ниже, а validation loss после раннего улучшения может расти: это согласуется с переобучением. В E скачок одновременно на train и validation указывает на проблему оптимизации при заданном режиме. Эти механизмы следует различать.

8. Обсуждение результатов и выводы

Почему нормы недостаточно для оценки скорости обучения

Градиент весов слоя имеет вид усреднённого внешнего произведения обратного сигнала δ_l и входной активации h_{l-1}. Поэтому его норма зависит и от ошибки, и от масштаба входов. В первой матрице 32·2 = 64 элемента, в последующих скрытых матрицах 32·32 = 1024; нормы Фробениуса разных слоёв не нормированы по числу элементов. Нельзя напрямую интерпретировать их отношение как чистую меру затухания обратного сигнала.

Изменение loss зависит от направления шага, LR, геометрии функции и оптимизатора. Adam преобразует градиенты с учётом накопленных моментов, поэтому норма исходного градиента не равна норме обновления. Диагностика проводится на одном train-batch, тогда как validation loss измеряет качество на других объектах. Большая норма не гарантирует быстрое снижение validation loss.

Основные выводы

1. Раннее обучение глубокой Sigmoid затруднено. При обоих seed начальный g_1 в A в 433/643 раза меньше g_6; порог val loss 0.2 достигается на эпохах 66/56 против 4/4 у C. Это согласуется с ослаблением произведения производных Sigmoid по правилу цепочки. К эпохе 100 A всё же достигает хорошего качества, и универсального итогового превосходства ReLU наблюдения не подтверждают.

2. Масштаб инициализации влияет на градиенты, но не гарантирует обобщение. В ReLU переход Xavier → He повышает стартовый g_1 с 0.045 до 0.309 для seed 11 и ускоряет часть ранней динамики к эпохе 20. При этом средний итоговый validation loss D (0.2093) выше C (0.2024). Норма градиента не является самостоятельной мерой качества.

3. Более сильная подгонка train не обеспечивает лучшее качество validation. У D при seed 29 train loss 0.1141, у F - 0.1382; validation loss соответственно 0.2063 и 0.1676. Выбранная F с 162 параметрами имеет меньший средний validation loss, чем D с 5442 параметрами. Результат согласуется с различием ёмкости моделей и обобщения, но не изолирует эффект глубины.

Ограничения исследования

Недостаточно данных для утверждения «Adam всегда лучше SGD», «He всегда лучше Xavier» или «мелкие сети всегда обобщают лучше глубоких». В D/E одновременно меняются оптимизатор и LR, в D/F - глубина и число параметров. A-C исследованы только с Xavier gain=1.0. Два seed и одно разбиение не дают надёжной оценки распределения качества или статистической значимости; LR фиксированы и не подбирались.