Диагностика обучения MLP

Отчёт по лабораторной работе № 1

Цель работы. Исследовать влияние функций активации, инициализации весов, глубины многослойного перцептрона и режима оптимизации на обучение и качество бинарной классификации. Проведено 12 экспериментов: шесть конфигураций модели с двумя значениями начального состояния генератора случайных чисел (seed).

1. Подготовка данных

Сгенерированы 2400 объектов командой make_moons(n_samples=2400, noise=0.25, random_state=2026). Два последовательных стратифицированных train_test_split используют random_state=2026 и test_size=0.2, затем 0.25. Разбиение одинаково для всех экспериментов.

Выборка	Объекты	Класс 0	Класс 1
train	1440	720	720
validation	480	240	240
test	480	240	240

Параметры стандартизации StandardScaler рассчитаны только по обучающей выборке. Средние значения признаков после преобразования составили 2.066e-17 и 6.216e-16, стандартные отклонения - 1.000000 и 1.000000. Таким образом, признаки центрированы и имеют единичную дисперсию. Исключение validation и test из расчёта параметров стандартизации предотвращает утечку информации.

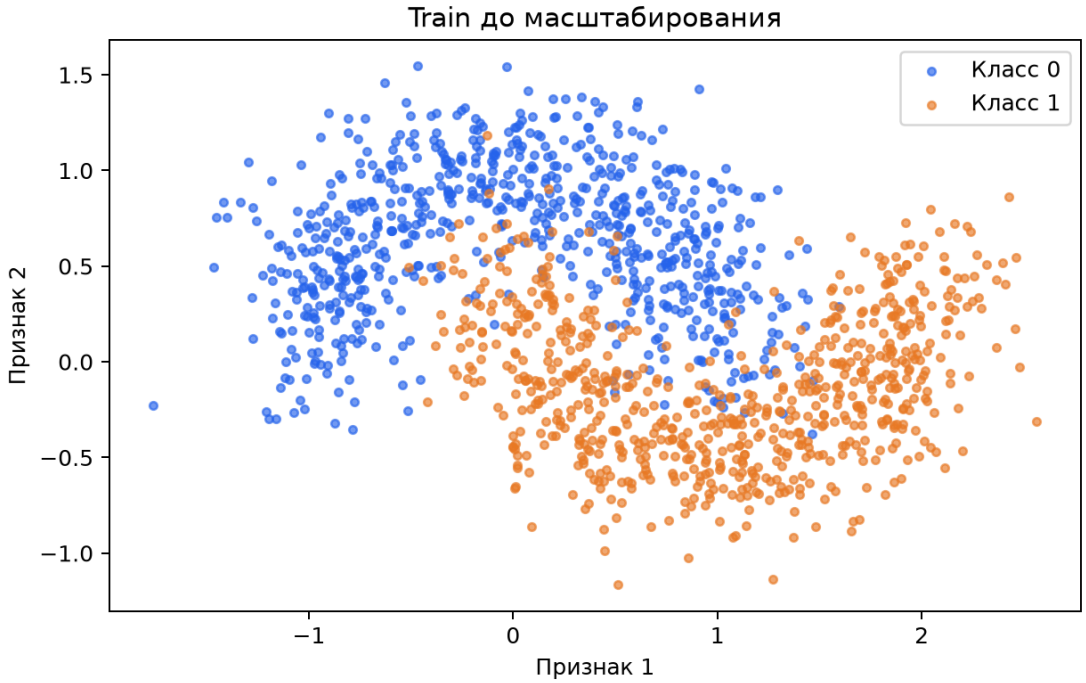


Рисунок 1. Исходные обучающие объекты до масштабирования, цветом обозначен класс.

2. Архитектура и протокол обучения

MLP получает два признака, содержит L полносвязных скрытых слоёв ширины 32 и линейный выход из двух логитов. Во всех скрытых слоях одного запуска используется одна активация. Softmax перед CrossEntropyLoss не применяется.

$$h_0 = x;\ z_l = W_l h_{l-1} + b_l;\ h_l = \varphi(z_l),\ l = 1,\ldots,L.$$
$$z_{out} = W_{L+1} h_L + b_{L+1} \in R^2.$$

Первый скрытый слой имеет W формы (32, 2), остальные - (32, 32), выходной - (2, 32). Размеры bias: 32 для скрытых слоёв и 2 для выхода.

Число параметров

$N(L) = (2\cdot32 + 32) + (L - 1)\cdot(32\cdot32 + 32) + (32\cdot2 + 2)$.
$N(1) = 162$; $N(6) = 5442$. Аналитический расчёт совпал с программным подсчётом числа обучаемых параметров.

Код	L	Активация	Скрытые веса	Оптимизатор	LR
A	6	Sigmoid	Xavier normal	Adam	0.003
B	6	Tanh	Xavier normal	Adam	0.003
C	6	ReLU	Xavier normal	Adam	0.003
D	6	ReLU	He normal	Adam	0.003
E	6	ReLU	He normal	SGD	0.05
F	1	ReLU	He normal	Adam	0.003

Xavier normal задан с gain=1.0. He/Kaiming normal - с mode=fan_in, nonlinearity=relu. Выходной Linear во всех вариантах инициализирован Xavier normal с gain=1.0, все bias равны нулю. Для SGD установлен momentum=0; остальные параметры оптимизаторов, кроме LR, оставлены по умолчанию.

Методика обучения

Использованы слои torch.nn, дифференцирование autograd и оптимизаторы SGD/Adam. Конструктор MLP, инициализация, цикл обучения, расчёт метрик и диагностика градиентов реализованы самостоятельно.

Каждый запуск: 100 эпох, batch size 128, перемешивание train в каждой эпохе. До создания модели вызывается torch.manual_seed(seed), для DataLoader создаётся новый torch.Generator().manual_seed(10000 + seed). Seed: 11 и 29. Устройство cpu, torch.set_num_threads(1), признаки float32, метки torch.long.

На каждом шаге градиенты обнуляются через zero_grad, затем выполняются прямой проход, расчёт CrossEntropyLoss(mean), backward и optimizer.step. На эпохе 0 и после каждой эпохи loss и accuracy оцениваются на полных train и validation в eval/no_grad; перед обучением включается train. Accuracy вычисляется через argmax как доля от 0 до 1. Проверяется конечность loss. Scheduler, dropout, batch normalization, weight decay, early stopping и предварительное обучение отсутствуют.

Контроль корректности реализации

При L=1 и L=6 вход и выход имеют размерность (8, 2), функция потерь скалярна. Градиенты всех скрытых весов существуют, конечны и совпадают по размерностям с соответствующими матрицами весов.

3. Итоговые метрики всех запусков

Таблица 1. Метрики эпохи 100. Accuracy указана долей правильных ответов.

Код	Seed	Train loss	Train acc.	Val loss	Val acc.
A	11	0.150452	0.945833	0.190750	0.916667
A	29	0.140309	0.945833	0.177103	0.916667
B	11	0.146706	0.946528	0.203395	0.912500
B	29	0.143581	0.948611	0.189271	0.918750
C	11	0.120760	0.951389	0.180691	0.920833
C	29	0.129302	0.945833	0.224080	0.910417
D	11	0.108775	0.953472	0.212312	0.922917
D	29	0.114085	0.952083	0.206341	0.914583
E	11	0.254591	0.884722	0.346126	0.858333
E	29	0.303343	0.865278	0.355739	0.839583
F	11	0.136744	0.949306	0.167788	0.929167
F	29	0.138208	0.949306	0.167623	0.922917

Таблица 2. Средний validation loss эпохи 100 по двум seed.

Конфигурация	A	B	C	D	E	F
Mean val loss	0.183927	0.196333	0.202386	0.209326	0.350932	0.167705

Активации при Xavier normal

При seed 11 validation loss для A/B/C составил 0.6935/0.3522/0.4296 на эпохе 1 и 0.3445/0.1745/0.2112 на эпохе 20. Sigmoid обучается заметно медленнее; впервые val loss ниже 0.2 достигается на эпохах 66/5/4. На эпохе 100 порядок меняется: C (0.1807) лучше A (0.1908) и B (0.2034).

При seed 29 раннее отставание A повторяется: loss эпохи 20 для A/B/C составляет 0.3271/0.1741/0.1755; порог 0.2 достигнут на эпохах 56/4/4. Однако на эпохе 100 A (0.1771) лучше B (0.1893) и C (0.2241). Раннее замедление Sigmoid устойчиво в этих двух запусках, итоговое превосходство ReLU - нет. Вывод относится к Xavier normal с gain=1.0.

Инициализация ReLU

Дисперсия He равна 2/fan_in, Xavier - 2/(fan_in + fan_out): в квадратных слоях это 2/32 против 1/32, в первом - 1 против 2/34. Масштаб меняет активации и градиенты. На эпохе 20 переход от C к D снижает validation loss с 0.2112 до 0.1704 при seed 11 и с 0.1755 до 0.1690 при seed 29. Но на эпохе 100 D хуже C при seed 11 и лучше при seed 29. Средний итоговый loss D (0.2093) выше C (0.2024); He не гарантирует лучшую validation-оценку.

4. Динамика обучения и сравнения режимов

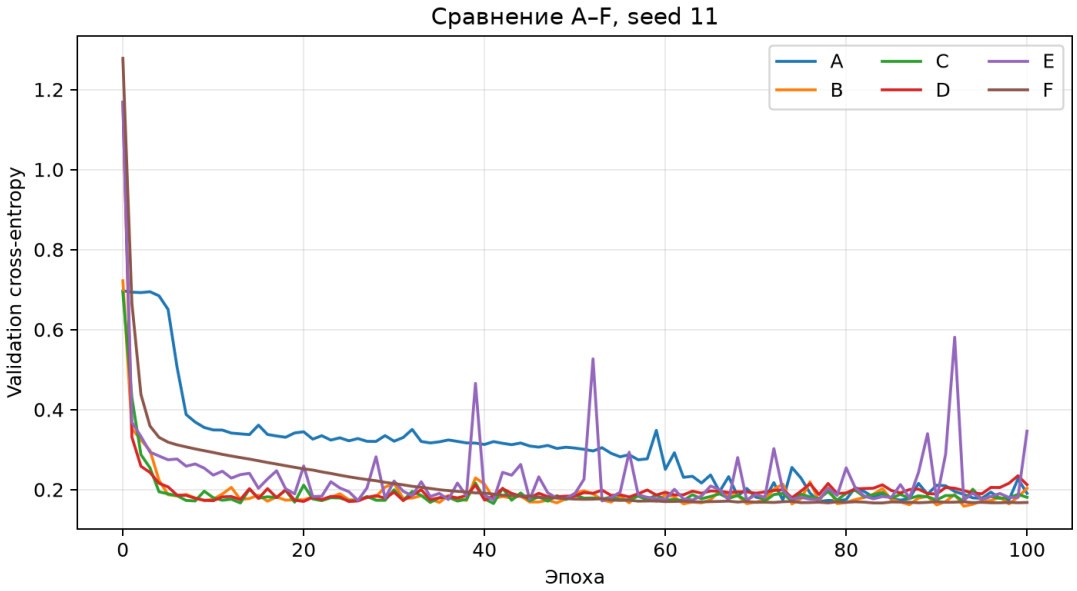


Рисунок 2. Validation loss A-F по эпохам, seed 11.

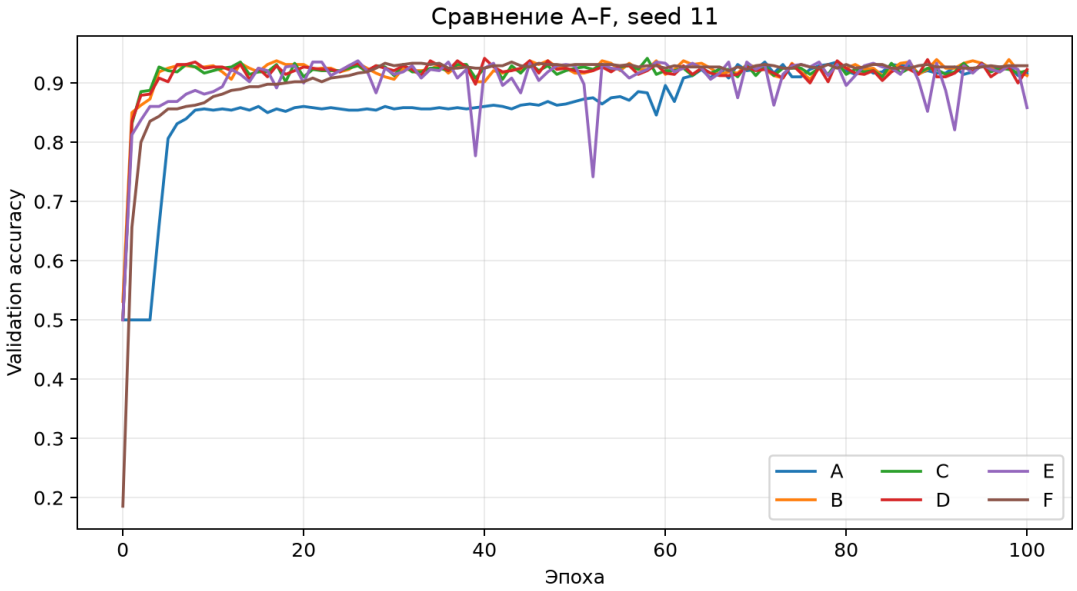


Рисунок 3. Validation accuracy A-F по эпохам, seed 11.

D/E. Порог val loss ниже 0.2 достигнут D на эпохах 6/5, E - на 19/21 (seed 11/29). На эпохе 100 D лучше E для обоих seed. В E между эпохами 99 и 100 train loss растёт с 0.1277 до 0.2546 и с 0.1337 до 0.3033; одновременно растёт validation loss. Одновременное ухудшение на обеих выборках указывает на нестабильность оптимизации; одного переобучения для объяснения такого скачка недостаточно. Сравнение относится к Adam 0.003 и SGD 0.05: влияние оптимизатора отдельно от LR не установлено.

D/F. D быстрее достигает порога 0.2 (6/5 против 35/42 эпох), но F имеет меньший итоговый validation loss при обоих seed. У D ниже потери на обучающей выборке: 0.1141 против 0.1382 у F для seed 29. В D 5442 параметра против 162 у F; влияние глубины нельзя отделить от изменения числа параметров.

5. Диагностика градиентов по слоям

Контрольный batch - первые 128 объектов train после разбиения и масштабирования в сохранённом порядке. На эпохах 0, 20 и 100 отдельно выполняются zero_grad, forward, backward, измерение нормы и повторный zero_grad; параметры не обновляются. Измеряется $g_l(t) = ||\partial CE(f_\theta(t)(X_{probe}), y_{probe})/\partial W_l||_F$.

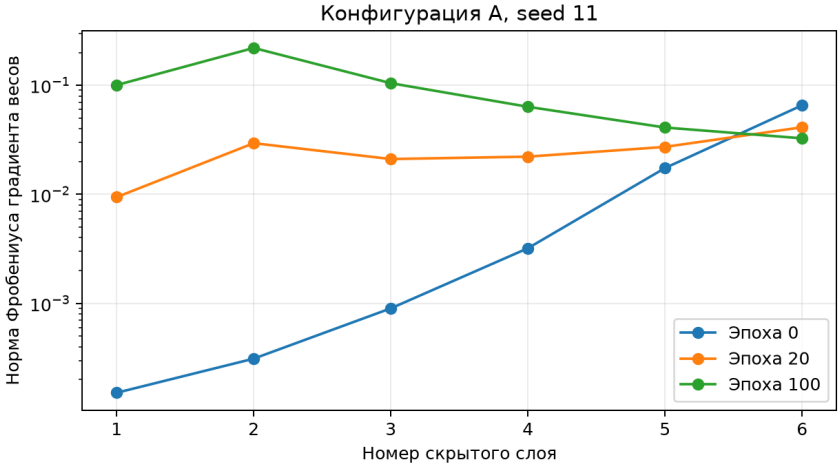


Рисунок 4. Нормы градиентов скрытых весов A, seed 11; логарифмическая ось Y.

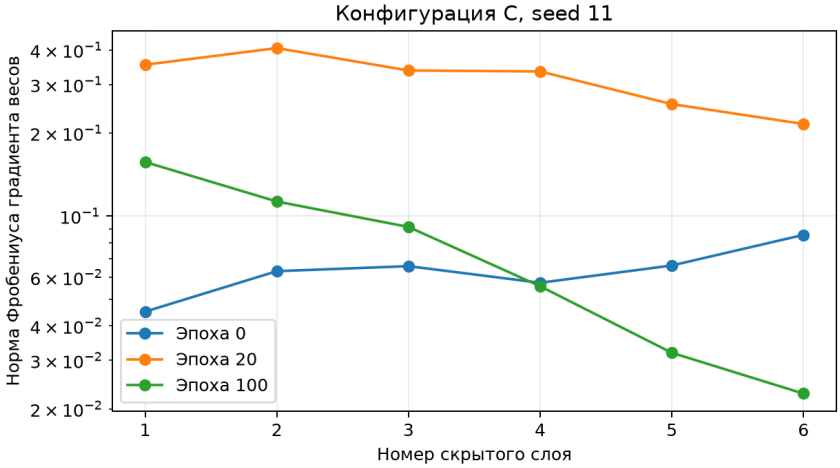


Рисунок 5. Нормы градиентов скрытых весов C, seed 11; логарифмическая ось Y.

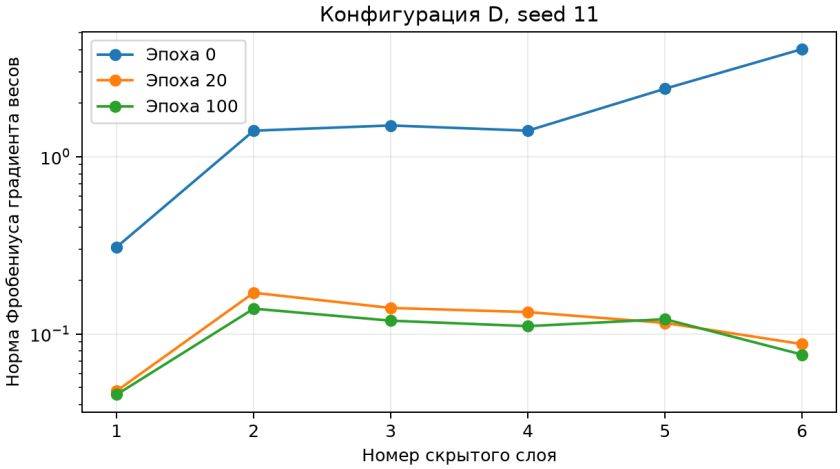


Рисунок 6. Нормы градиентов скрытых весов D, seed 11; логарифмическая ось Y.

6. Объяснение градиентной диагностики

Таблица 3. Нормы градиентов весов первого и последнего скрытых слоёв для двух значений seed.

Код	Seed	Эпоха	g_1	g_6
A	11	0	1.516e-04	6.565e-02
A	11	20	9.437e-03	4.127e-02
A	11	100	1.005e-01	3.265e-02
A	29	0	1.902e-04	1.223e-01
A	29	20	1.033e-02	3.373e-02
A	29	100	7.405e-02	1.929e-03
C	11	0	4.505e-02	8.548e-02
C	11	20	3.538e-01	2.158e-01
C	11	100	1.570e-01	2.273e-02
C	29	0	9.655e-02	9.255e-02
C	29	20	1.423e-01	2.937e-02
C	29	100	3.022e-01	3.137e-02
D	11	0	3.088e-01	4.039e+00
D	11	20	4.771e-02	8.762e-02
D	11	100	4.549e-02	7.643e-02
D	29	0	2.654e-01	9.643e-01
D	29	20	1.239e-01	1.214e-01
D	29	100	1.515e-01	1.022e-01

Sigmoid и правило цепочки. При seed 11 начальные g_1/g_6 в A равны 1.516e-04/6.565e-02: ранний слой имеет примерно в 433 раза меньшую норму. При seed 29 разница составляет 643 раза. Производная Sigmoid не превышает 1/4. При обратном распространении произведение таких множителей может ослаблять сигнал. В C начальные нормы первого и шестого слоёв одного порядка: 0.045/0.085 и 0.097/0.093. У активных ReLU производная равна 1; однако веса и неактивные нейроны также влияют на результат.

C/D. На эпохе 0 Не повышает g_1 с 0.045 до 0.309 (seed 11) и с 0.097 до 0.265 (seed 29); масштаб g_6 также выше. На эпохе 100 в D g_1 ниже C, а g_6 выше C для обоих seed. Большая начальная норма не гарантирует меньших итоговых потерь на validation.

Все 108 норм конечны и положительны. Основные наблюдения повторяются на seed 29: ослабление раннего градиента A в начале и увеличение начальных норм D относительно C. Конкретные величины после обучения сильно различаются.

7. Выбор модели и оценка обобщения

Конфигурацию выбирали по среднему validation loss на эпохе 100 для двух значений seed. Затем внутри неё выбирали запуск с меньшим validation loss. При точном равенстве предпочтение отдавалось более ранней букве конфигурации и seed 11. Промежуточные эпохи в выборе не участвовали.

Наименьший средний validation loss получила F: 0.167705. Для seed 11 значение составило 0.167788, для seed 29 - 0.167623, поэтому выбран второй запуск. Для оценки на test использованы его веса после эпохи 100. Результаты test не влияли на выбор или настройки модели.

Выборка	Cross-entropy loss	Accuracy
Train	0.138208	0.949306
Validation	0.167623	0.922917
Test	0.131385	0.950000

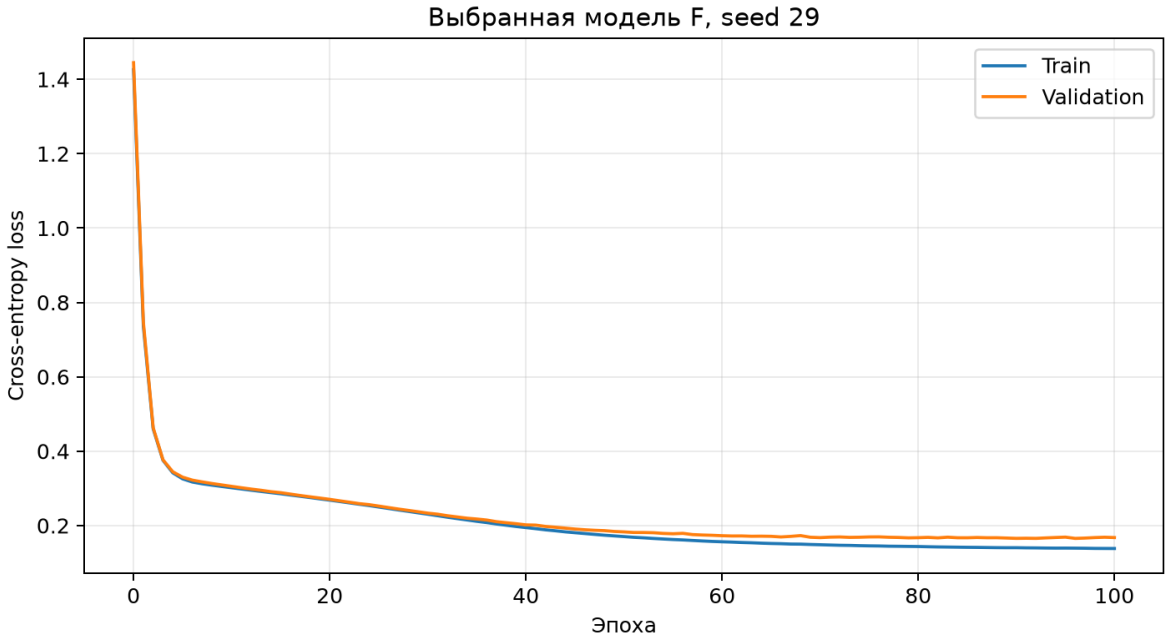


Рисунок 7. Train и validation loss выбранного запуска F, seed 29.

На train модель правильно классифицирует 94.93% объектов; loss снижается с 1.4259 до 0.1382. На validation потери изменились с 1.4447 до 0.1676; разрыв с train на последней эпохе равен 0.0294.

У F потери на validation немного выше, чем на train. По ходу обучения обе кривые снижаются, поэтому разрыв на последней эпохе сам по себе не доказывает сильного переобучения. На test accuracy составила около 0.95. Более низкие потери на test по сравнению с validation могут быть связаны с составом выборок и шумом в данных. Оценка относится к одному разбиению.

У глубокой D потери на train ниже, но на validation после начального снижения могут расти. Такая динамика согласуется с переобучением. У E одновременно растут потери на train и validation, что указывает на нестабильность оптимизации при выбранных настройках.

8. Обсуждение результатов и выводы

Связь градиентов с изменением функции потерь

Градиент весов слоя имеет вид усреднённого внешнего произведения обратного сигнала δ_l и входной активации h_{l-1}. Поэтому его норма зависит и от ошибки, и от масштаба входов. Первая матрица содержит 64 элемента при размере 32 на 2, остальные скрытые матрицы - по 1024 элемента при размере 32 на 32; нормы Фробениуса разных слоёв не нормированы по числу элементов. Нельзя напрямую интерпретировать их отношение как чистую меру затухания обратного сигнала.

Изменение loss зависит от направления шага, LR, геометрии функции и оптимизатора. Adam преобразует градиенты с учётом накопленных моментов, поэтому норма исходного градиента не равна норме обновления. Диагностика проводится на одном train-batch, тогда как validation loss измеряет качество на других объектах.

Основные выводы

1. У глубокой сети с Sigmoid начальная норма градиента первого слоя была в 433 и 643 раза меньше нормы последнего слоя для seed 11 и 29. Validation loss опустился ниже 0.2 лишь на эпохах 66 и 56; у ReLU в конфигурации C это произошло на эпохе 4 в обоих запусках. Медленный старт Sigmoid согласуется с ослаблением градиента при перемножении производных. К эпохе 100 сеть A обучилась, а преимущество ReLU по итоговым потерям зависело от seed.

2. Замена Xavier на He в сети с ReLU увеличила начальную норму градиента первого слоя с 0.045 до 0.309 при seed 11. К эпохе 20 потери на validation у D были ниже, чем у C. Однако среднее значение на эпохе 100 оказалось выше: 0.2093 против 0.2024. В этих опытах больший масштаб начальных градиентов не дал выигрыша в итоговом качестве.

3. У глубокой сети D ниже потери на train, но выше на validation по сравнению с F. При seed 29 потери на train составили 0.1141 у D и 0.1382 у F; на validation - 0.2063 и 0.1676. Модель F с 162 параметрами получила меньший средний validation loss, чем D с 5442 параметрами. Отделить влияние глубины от числа параметров по этому сравнению нельзя.

Ограничения исследования

Недостаточно данных для утверждения «Adam всегда лучше SGD», «He всегда лучше Xavier» или «мелкие сети всегда обобщают лучше глубоких». В D/E одновременно меняются оптимизатор и LR, в D/F - глубина и число параметров. A-C исследованы только с Xavier gain=1.0. Два seed и одно разбиение не дают надёжной оценки распределения качества или статистической значимости; LR фиксированы и не подбирались.